

به نام خدا



دانشگاه کاشان، دانشکده برق و
کامپیوتر

درس یادگیری ماشین

مدرس: دکتر جواد سلیمی سرتختی

تمرین شماره صفر

نام و نام خانوادگی : سیدپرهام میرطلائی

شماره دانشجویی : 40321570014

پاییز و زمستان 1403

3	مقدمه.....
4	فاز اول :.....
6	فاز دوم :.....
8	فاز سوم :.....
9	فاز چهارم :.....
13	فاز پنجم :.....

در دنیای امروز، اطلاعات و داده ها به یکی از ارزشمندترین دارایی های هر کسب و کار تبدیل شده اند. در این پروژه، ما به بررسی یک دیتاست مربوط به فروش و مشتریان یک شرکت خواهیم پرداخت. این دیتاست شامل اطلاعاتی مانند تاریخ خرید، نوع محصولات، میزان فروش و ویژگی های مشتریان است.

هدف اصلی ما از این تحلیل، درک بهتر رفتار مشتریان و شناسایی الگوهای خرید آنهاست. با تحلیل این داده ها، می توانیم ببینیم کدام محصولات بیشتر فروش می روند، چه زمانی از سال مشتریان بیشتر خرید می کنند و همچنین ویژگی های مشترک مشتریانی که وفادارتر هستند چیست.

این اطلاعات نه تنها به شرکت کمک می کند تا تصمیمات بهتری در زمینه بازاریابی و فروش بگیرد، بلکه می تواند به بهبود تجربه مشتری نیز منجر شود. در نهایت ما با استفاده از این تحلیل ها می توانیم راهکارهایی برای افزایش فروش و رضایت مشتریان ارائه دهیم.

فاز اول :

قسمت اول:

خب، من یه کپی از دیتافریم اصلی درست کردم و بعد از اون، تمام ردیف‌هایی که شماره مشتری (CustomerId) نداشتن رو حذف کردم. این کار باعث شد که فقط اطلاعات مشتری‌هایی که شماره دارند توی دیتافریم بمونه. در نهایت، با استفاده از دستور ، چند تا از ردیف‌های اول این دیتافریم جدید رو بررسی کردم تا ببینم همه‌چیز درست شده یا نه. به طور خلاصه، هدف این بود که مطمئن بشم فقط مشتری‌های معتبر و دارای شماره توی دیتافریم باقی بمونن.

قسمت دوم:

من یه نسخه از دیتافریم اصلی درست کردم و بعد از اون، تمام ردیف‌هایی که شماره مشتری نداشتن رو حذف کردم. حالا می‌خواستم مطمئن بشم که هیچ کدوم از شماره‌های مشتری تکراری نیستن. به همین خاطر، از یک دستور استفاده کردم که همه‌ی ردیف‌های تکراری رو پاک کنه.

چند تا از ردیف‌های اول این دیتافریم جدید رو بررسی کردم تا ببینم همه‌چیز مرتب شده یا نه. به این ترتیب، فقط مشتری‌های معتبر و بدون تکرار توی دیتا فریم باقی موندن.

قسمت سوم:

من یه کپی از دیتافریم اصلی درست کردم و بعدش تصمیم گرفتم که فقط ردیف‌هایی رو نگه دارم که قیمت واحد (UnitPrice) اون‌ها بیشتر از صفر باشه. به این ترتیب، تمام ردیف‌هایی که قیمت نداشتن یا قیمتشون صفر بود رو حذف کردم.

در آخر چند تا از ردیف‌های اول این دیتافریم جدید رو بررسی کردم تا ببینم همه‌چیز مرتب شده و قیمت‌ها درست هستن یا نه. به این شکل، فقط اطلاعات معتبر و با قیمت‌های مثبت توی دیتافریم باقی موند.

قسمت چهارم:

من اول دیتافریم رو طوری تغییر دادم که شماره‌های فاکتور (InvoiceNumber) به صورت رشته (string) ذخیره بشن. بعد از این کار، تعداد کل فاکتورها رو حساب کردم تا ببینم چقدر فاکتور داریم.

سپس، فاکتورهایی که با حرف "C" شروع می‌شدن (که نشون دهنده‌ی سفارش‌های لغو شده هستن) رو جدا کردم و تعدادشون رو هم شمردم.

بعد اون درصد سفارش‌هایی که لغو شده بودن رو محاسبه کردم. به این ترتیب، تونستم بفهمم چه مقدار از کل سفارش‌ها به لغو شده‌ها مربوط میشه. این اطلاعات می‌تونه به ما کمک کنه تا وضعیت سفارش‌ها رو بهتر درک کنیم.

قسمت پنجم:

خب اول فاکتورهایی که لغو شده بودن رو جدا کردم و دیدم که کدوم مشتری‌ها بیشتر از بقیه سفارش‌ها رو لغو کردن. برای این کار، ابتدا فاکتورهایی که با حرف "C" شروع می‌شدن رو پیدا کرده بودم و بعد بر اساس شناسه مشتری (CustomerId) تعداد فاکتورهای لغو شده رو حساب کردم.

بعد از اینکه تعداد فاکتورهای لغو شده برای هر مشتری رو مشخص کردم، لیست مشتری‌هایی که بیشترین لغو سفارش رو داشتن، مرتب کردم. در نهایت، پنج مشتری اولی که بیشترین سفارش‌های لغو شده رو داشتن، انتخاب کردم و شناسه‌های اون‌ها رو به صورت یک لیست آماده کردم.

هدف این اطلاعات این است که به ما کمک کنه تا بفهمیم کدوم مشتری‌ها بیشتر از بقیه تمایل به لغو سفارش‌ها دارن و شاید بتونیم راه‌حلی برای این موضوع پیدا کنیم.

قسمت ششم:

یک کپی از داده های اصلی ام درست کردم و اسمش رو گذاشتم `df_no_canceled_invoice`. بعدش تصمیم گرفتم که فاکتورهایی که لغو شده بودن رو از این کپی حذف کنم. برای این کار، همه فاکتورهایی که شماره شون با حرف "C" شروع می شد رو پیدا کردم و از داده ها حذف کردم.

با استفاده از تابع `head()` (نگاهی به چند ردیف اول از این داده های جدید انداختم تا مطمئن بشم که فاکتورهای لغو شده به درستی حذف شدن یا نه. به این ترتیب، حالا فقط فاکتورهایی دارم که لغو نشده اند.

فاز دوم :

قسمت اول:

من با استفاده از کدی که نوشتم، تعداد فاکتورها یا سفارش هایی که توی دیتافریم دارم رو حساب کردم. این کار رو با استفاده از تابع `nunique()` انجام دادم که فقط شماره های منحصر به فرد فاکتورها رو می شمارد. به این ترتیب، تونستم بفهمم چند تا سفارش مختلف توی داده هام وجود داره. نتیجه اش رو هم توی متغیر `number_of_orders` ذخیره کردم تا بعداً ازش استفاده کنم.

قسمت دوم:

توی کدم من بازه زمانی مربوط به تاریخ فاکتورها رو مشخص کردم. با استفاده از تابع `min()` تاریخ اولین فاکتور و با `max()` تاریخ آخرین فاکتور رو پیدا کردم. به این ترتیب، متوجه شدم که سفارش ها از چه تاریخی شروع می شن و تا چه تاریخی ادامه دارن. نتیجه این کار رو هم توی متغیر `window_period` ذخیره کردم تا بعداً بتونم ازش استفاده کنم. به عبارتی، یک نمای کلی از زمان بندی فاکتورها به دست آوردم.

قسمت سوم:

در این کد، من به تحلیل فاکتورها بر اساس روزهای هفته پرداختم. اول از همه، تاریخ فاکتورها رو به فرمت مناسب تبدیل کردم تا بتونم ازش استفاده کنم. بعد با استفاده از تابع `day_name()`، نام روزهای هفته رو برای هر فاکتور استخراج کردم.

سپس، با گروه بندی داده‌ها بر اساس روزها، تعداد فاکتور ها رو برای هر روز محاسبه کردم. به این ترتیب، متوجه شدم که در هر روز چند تا سفارش ثبت شده است.

برای نمایش این اطلاعات، یک نمودار میله‌ای طراحی کردم که تعداد سفارش‌ها رو برای هر روز هفته نشون میده. در نهایت، عنوان و برچسب های محورهای نمودار رو هم تنظیم کردم تا خوانایی بهتری داشته باشه.

این کار به من کمک کرد تا بفهمم کدام روزها بیشترین و کمترین سفارش رو دارن و الگوهای خرید مشتریان رو بهتر بشناسم و بتوانم خیلی بهتر الگوها رو ببینم و تحلیل کنم.

قسمت چهارم:

توی این قسمت کد من به تحلیل فروش‌ها بر اساس ماه و سال پرداختم. ابتدا با ضرب قیمت واحد هر کالا در تعداد خریداری شده، مجموع قیمت هر فاکتور رو محاسبه کردم و در یک ستون جدید به نام `PriceTotal` ذخیره کردم.

بعد از اون، تاریخ فاکتورها رو به فرمت ماه و سال تبدیل کردم تا بتونم فروش‌ها رو بر اساس این دو گروه بندی کنم. بعد از این کار، با استفاده از تابع `groupby`، مجموع فروش‌ها رو برای هر ماه محاسبه کردم و نتایج رو در یک دیتافریم جدید به نام `sales_for_month` ذخیره کردم.

برای نمایش این اطلاعات، یک نمودار میله‌ای طراحی کردم که مجموع فروش‌ها رو برای هر ماه نشون میده. عنوان و برچسب های محورهای نمودار رو هم تنظیم کردم تا واضح تر باشه.

در نهایت، با این کار توانستم ببینم که در هر ماه چقدر فروش داشته ام و الگوهای فروش رو بهتر درک کنم. این اطلاعات می‌تونه به من کمک کنه تا استراتژی‌های بهتری برای فروش آن در آینده داشته باشم و برای آن برنامه‌ریزی کنم.

فاز سوم :

در این فاز کدهایی که زدم، من به تحلیل فروش‌ها بر اساس کشورها پرداختم. اول از همه، اطلاعات مربوط به کشور "بریتانیا" رو از دیتافریم حذف کردم تا تمرکز روی کشورهای دیگه باشه. بعد از اون، با ضرب قیمت واحد هر کالا در تعداد خریداری‌شده، مجموع فروش هر کشور رو محاسبه کردم و همچنین تعداد مشتری‌های هر کشور رو هم شمارش کردم.

سپس برای هر کشور، دو مقدار را محاسبه کردم: یکی مجموع فروش (**SalesAmount**) و دیگری تعداد مشتری‌ها (**NumberOfCustomer**). بعد از این، با استفاده از دو مقدار محاسبه‌شده، کشورهای مختلف رو به چهار گروه تقسیم‌بندی کردم:

- ✓ کشورهایی که هم فروش بالایی دارند و هم تعداد مشتری‌های زیادی دارن.
- ✓ کشورهایی که تعداد مشتری‌های زیادی دارند ولی فروش‌شون پایین‌تره.
- ✓ کشورهایی که فروش بالایی دارند اما تعداد مشتری‌هاشون کم‌تره.
- ✓ کشورهایی که هم فروش پایینی دارند و هم تعداد مشتری‌هاشون کم هست.

برای هر گروه، یک رنگ خاص انتخاب کردم تا در نمودار مشخص بشن. بعد از این کار، یک نمودار پراکندگی (**scatter plot**) طراحی کردم که در اون میزان فروش و تعداد مشتری‌ها برای هر کشور رو نشون میده.

در آخرم، نام کشورهای خاصی مثل فرانسه، اسپانیا و هلند رو هم روی نمودار اضافه کردم تا بهتر دیده بشن. همچنین یک راهنما (**legend**) برای توضیح گروه‌ها اضافه کردم تا بیننده راحت‌تر بتونه اطلاعات رو درک کنه.

هدف این فاز این بود که الگوهای فروش و مشتری ها رو در کشورهای مختلف ببینم و نقاط قوت و ضعف رو شناسایی کنم. این اطلاعات می تونه به من کمک کنه تا استراتژی های بهتری برای بازارهای مختلف طراحی کنم.

فاز چهارم :

معیار Recency

من تاریخ فاکتورها رو به فرمت تاریخ و زمان تبدیل کردم تا بتونم بهتر باهاش کار کنم. بعد از اون، آخرین تاریخی که در دیتا فریم وجود داشت رو پیدا کردم. به عبارتی، آخرین روزی که یه خرید انجام شده رو مشخص کردم.

سپس یک روز به این تاریخ اضافه کردم تا بتونم به راحتی با روز بعد از آخرین خرید هم کار کنم (چون گفته بودین در چنین روزی هم ما داریم تحلیل میکنیم). هدف این کار اینه که به من کمک می کنه تا در تحلیل ها و گزارش هام، اطلاعات دقیقی از زمان های مختلف داشته باشم و بتونم برنامه ریزی بهتری انجام بدم.

معیار Frequency

در این بخش از کد، من داشتم به اطلاعات مشتری ها نگاه می کردم. اول از همه، تعداد فاکتورهایی که هر مشتری داشته رو شمردم. یعنی بررسی کردم که هر مشتری چند بار خرید کرده.

بعد از اینکه این تعداد رو به دست آوردم، اون رو به دیتافریم اصلی مشتری ها اضافه کردم. به این ترتیب، حالا می تونم ببینم هر مشتری چقدر فعال بوده و چقدر خرید کرده.

در نهایت، با استفاده از **head()**، چند تا از اولین ردیف‌های این دیتافریم جدید رو نمایش دادم تا ببینم همه چیز درست پیش رفته یا نه. هدف این قسمت این بوده که میتونم بهتر بفهمم که مشتری‌ها چقدر با ما در ارتباط بودن و چقدر خرید کردن.

معيار Monetary Value

توی این کد اول از همه، یک ستون جدید به نام **TotalPrice** اضافه کردم که مجموع قیمت هر خرید رو محاسبه می‌کنه. این کار با ضرب کردن قیمت واحد (**UnitPrice**) در تعداد خرید (**Quantity**) انجام شد.

بعد از اینکه مجموع قیمت هر مشتری رو به دست آوردم، این اطلاعات رو گروه بندی کردم تا ببینم هر مشتری چقدر خرج کرده. نتیجه رو در یک دیتا فریم جدید به نام **monetary_data** ذخیره کردم و ستون هاش رو به نام‌های مناسب تغییر دادم تا مشخص بشه که هر مشتری چقدر ارزش مالی داره.

در نهایت، این اطلاعات رو به دیتافریم اصلی مشتری‌ها که قبلاً داشتم، اضافه کردم. به این ترتیب، حالا می‌تونم ببینم هر مشتری چه مقدار پولی خرج کرده و این اطلاعات رو برای تحلیل‌های بعدی استفاده کنم.

گروه بندی هر معيار

در این بخش از کد، من به تحلیل رفتار مشتری‌ها پرداختم و سعی کردم اون‌ها رو بر اساس سه ویژگی مهم دسته‌بندی کنم: (**Recency**)، (**Frequency**)، (**Monetary Value**).

اول از همه، برای هر یک از این ویژگی‌ها، سه نقطه‌ی مرزی به نام‌های چارک ۲۵، چارک ۵۰ و چارک ۷۵ محاسبه کردم. این نقاط به من کمک می‌کنند تا بفهمم مشتری‌ها در هر کدام از این جنبه‌ها چگونه عمل کردند.

سپس، یک تابع نوشتیم که بر اساس این نقاط مرزی، هر مشتری رو به یک گروه چهار قسمتی تقسیم می‌کند. به این صورت که:

- ✓ اگر مقدار یک ویژگی در ربع اول (چارک ۲۵) باشد، به گروه ۱ میره.
- ✓ اگر بین ربع اول و میانه (چارک ۵۰) باشه، به گروه ۲ میره.
- ✓ اگر بین میانه و ربع سوم (چارک ۷۵) باشه، به گروه ۳ میره.
- ✓ و اگر بیشتر از ربع سوم باشه، به گروه ۴ میره.

در آخرم برای هر مشتری سه ستون جدید اضافه کردم که نشون میده اون‌ها در کدام گروه برای هر یک از ویژگی‌ها قرار دارند. با استفاده از **head()** چند تا از اولین ردیف‌های دیتا فریم رو نمایش دادم تا ببینم همه چیز درست انجام شده یا نه. دیگه حالا می‌تونم مشتری‌ها رو بهتر بشناسم و رفتار اون‌ها رو تحلیل کنم.

معیار RFM

من تصمیم گرفتم که برای هر مشتری یک شناسه‌ی ترکیبی به نام **RFM** بسازم. این شناسه از سه قسمت تشکیل شده: **R** برای تازگی خرید، **F** برای تکرار خرید و **M** برای مقدار خرید. برای این کار، ابتدا هر کدام از این ویژگی‌ها رو به صورت عددی درآوردم و بعد با هم ترکیبشون کردم. به این صورت که:

- ✓ اول، مقدار هر کدام از ویژگی‌ها رو به رشته تبدیل کردم.
 - ✓ دوم اینکه رشته‌ها رو کنار هم گذاشتم تا یک کد واحد به نام **RFM** بسازم.
- در آخرم، این کد رو به عدد تبدیل کردم تا کار باهاش راحت‌تر بشه. هدف از این کار این بود که بتونم مشتری‌ها رو بهتر شناسایی کنم و رفتار خریدشون رو به راحتی تحلیل کنم.

گروه بندی مشتریان

من یک تابع به نام **group_rfm** نوشتم که وظیفه‌اش دسته‌بندی مشتری‌ها بر اساس شناسه ی **RFM** شونه. این تابع به هر مشتری یک برچسب می‌دهد که نشان‌دهنده ی وضعیت خریدشون هست.

برچسب‌ها به این صورت تعریف شده‌اند:

- ✓ **Best**: مشتریانی که بهترین رفتار خرید رو دارن.
- ✓ **AlmostLost**: مشتریانی که نزدیک به از دست رفتن هستن.
- ✓ **LostBigSpenders**: مشتریانی که قبلا خرید های زیادی داشتن اما الان دیگه خرید نمیکنن.
- ✓ **LostCheap**: مشتریانی که خرید های کمی داشتن و حالا دیگه خرید نمیکنن.
- ✓ **Loyal**: مشتریانی که وفادار هستن و مرتب خرید میکنند.
- ✓ **BigSpenders**: مشتریانی که خرید های بزرگ انجام میدن.
- ✓ **Normal**: بقیه ی مشتری ها که در هیچ کدوم از این دسته‌ها قرار نمی‌گیرن.

سپس، با استفاده از این تابع، به هر مشتری در دیتا فریم یک برچسب اضافه کردم تا بتونم بهتر گروه‌بندی کنم و رفتار خریدشون رو تحلیل کنم.

در نهایت، چند ردیف اول دیتافریم رو نمایش دادم تا ببینم همه چیز درست پیش رفته یا نه. هدف این کار این بود که بتونم مشتری‌ها رو بهتر بشناسم و استراتژی‌های بازاریابی مناسبی برای هر گروه طراحی کنم.

توی این فاز من به تحلیل رفتار مشتری‌ها بر اساس زمان خریدشون می پردازم.

تبدیل تاریخ‌ها: ابتدا تاریخ‌های خرید (**InvoiceDate**) رو به فرمت تاریخ استاندارد تبدیل کردم تا بتونم باهاشون کار کنم.

تعیین ماه خرید: برای هر خرید، ماه مربوط به اون خرید رو استخراج کردم و در یک ستون جدید به نام **InvoiceMonth** ذخیره کردم.

شناسایی اولین خرید: برای هر مشتری، ماهی که اولین بار خرید کرده رو پیدا کردم و در ستونی به نام **FirstPurchaseMonth** ذخیره کردم.

محاسبه شاخص هم گروهی: با استفاده از تاریخ اولین خرید و تاریخ هر خرید، یک شاخص به نام **CohortIndex** محاسبه کردم که نشون‌دهنده فاصله‌ی زمانی بین اولین خرید و خرید های بعدی به صورت ماهیانه بود.

گروه‌بندی داده‌ها: سپس با استفاده از گروه‌بندی، تعداد مشتری‌های منحصر به فرد در هر گروه (هم گروهی) و هر ماه رو محاسبه کردم و در یک جدول به نام **cohort_data** ذخیره کردم.

محاسبه نرخ نگهداری: با استفاده از داده‌های گروه‌بندی شده، نرخ نگهداری مشتری‌ها رو محاسبه کردم. این نرخ نشون میده که چه درصدی از مشتری‌ها در ماه‌های بعدی هنوز فعال هستند.

نقشه حرارتی: در نهایت، با استفاده از نقشه حرارتی (**heatmap**)، نتایج رو بصری‌سازی کردم تا بتونم به راحتی تغییرات نرخ نگهداری رو ببینم. این نقشه نشون میده که چقدر مشتری‌ها در طول زمان وفادار باقی موندن.

هدف از این کار، شناسایی الگوهای رفتاری مشتری‌ها و میزان وفاداری شون بود تا بر اساس اون بتونم استراتژی‌های بازاریابی و خدمات مشتری رو بهبود ببخشم. با این تحلیل می‌تونم بفهمم کدوم گروه از مشتری‌ها نیاز به توجه بیشتری دارن و کجاها باید تلاش بیشتری کنم تا مشتری‌ها رو حفظ کنم.